

SAS演習

NCD Epidemiology Research Center (NERC)
Department of Medical statistics

Akiko HARADA

0. Course series orientation

コースの進め方

•本コースの目的

- 医学研究における統計的手法を理解し、活用すること
- 臨床研究よりも疫学研究での応用に重点を置いて講義する。

•各講義(パート)

• シリーズ前半 (基礎編 Fundamental)

- 統計パッケージを用いて、基本的な統計手法の復習を行う。

• シリーズ後半 (*応用編 Advances)

- 疫学研究論文で使用されている統計手法の例を通して、研究テーマやデータの特徴に適した統計手法を学びます。

*受講はオプション

コース構成

本講座は、以下の11回に分けて実施します。

I Fundamental シリーズ

- 1 イントロ
- 2 2群の比較 (Continuous and Categorical data)
- 3 一般線形モデル(1) 回帰分析
- 4 一般化線形モデル ロジスティック回帰, Poisson回帰
- 5 生存時間分析
- 6 主成分分析, 因子分析, クラスター分析, 潜在クラス分析

II Advanced シリーズ

- 7 一般線形モデル (2) ANOVA 混合モデル
- 8 Reporting Guide: PRISMA Meta-analysis
- 9 Reporting Guide: CONSORT/STROBE
- 10 欠測データの解析, 相関のあるデータの解析: 一般化線形混合モデル
- 11 因果推論入門 (非巡回有向グラフ (DAG), 傾向スコア, mediation analysis)
~ SAS Causaltrt/Causalmixed/Causalgraph/PSmatch ~

Recommendations for Statistical Reporting in Cardiovascular Medicine. Circulation. 2021;144:e70–e91

Circulation

AAA SPECIAL REPORT

Recommendations for Statistical Reporting in Cardiovascular Medicine

A Special Report From the American Heart Association

Arora R, Arora R, Patel R, et al. (2021) *Circulation* 144:e70–e91. doi:10.1161/CIRCULATION.121.054000

Abstract Statistical analysis and its correct interpretation of the scientific research process are an essential part of evidence-based medicine. The American Heart Association (AHA) has developed a series of guidelines to help researchers and clinicians understand the importance of statistical reporting in cardiovascular medicine. These guidelines are intended to be used as a reference for researchers and clinicians who are involved in the reporting of statistical results in cardiovascular medicine. The guidelines are organized into 12 sections: 1. General Standards, 2. Observational Studies: Diagnostic Tests and Validation, 3. Observational Studies: Clinical Prediction Models, 4. Statistical Genetics, 5. Randomized Controlled Trials, 6. Systematic Reviews and Meta-Analyses, 7. Survival Analyses, 8. Bayesian Statistical Approaches, 9. Missing Data, 10. Correlated Data, 11. Covariate Adjustment and Propensity Scores, 12. Power and Sample Size Considerations.

1.1. Existing Guidelines

The AHA journals encourage authors to follow relevant existing guidelines when applicable (<https://www.aha.org/statistics>).

Study Type	Reporting guideline	Additional info
Body parameters	STROBE	STROBE-RR
Observational studies	STROBE	STROBE-RR
Diagnostic/prognostic studies	STROBE	STROBE-RR
Experimental data	CONSORT	CONSORT-RR
Systematic reviews	PRISMA	PRISMA-RR

For more information, see the [CONSORT website](https://www.aha.org/statistics). **CONSORT** indicates Consolidated Standards of Reporting Trials; **STROBE**, Strengthening of Reporting of Observational Studies in Epidemiology; **PRISMA**, Preferred Reporting Items for Systematic Reviews and Meta-Analyses; **STROBE-RR**, Standardized Reporting Items for Systematic Reviews and Meta-Analyses; **CONSORT-RR**, Consolidated Standards of Reporting Trials for Randomized Controlled Trials; **PRISMA-RR**, Preferred Reporting Items for Systematic Reviews and Meta-Analyses.

DATA FORCE CHARGE AND APPROACH

The American Heart Association (AHA) has developed a series of guidelines to help researchers and clinicians understand the importance of statistical reporting in cardiovascular medicine. These guidelines are intended to be used as a reference for researchers and clinicians who are involved in the reporting of statistical results in cardiovascular medicine. The guidelines are organized into 12 sections: 1. General Standards, 2. Observational Studies: Diagnostic Tests and Validation, 3. Observational Studies: Clinical Prediction Models, 4. Statistical Genetics, 5. Randomized Controlled Trials, 6. Systematic Reviews and Meta-Analyses, 7. Survival Analyses, 8. Bayesian Statistical Approaches, 9. Missing Data, 10. Correlated Data, 11. Covariate Adjustment and Propensity Scores, 12. Power and Sample Size Considerations.

Advanceシリーズでは、Circulation CVD statガイドラインの項目を参考に、FundamentalシリーズやReportingガイドラインに記載されていない項目を取り上げて、項目の充実に努めます。

5

本講座の受講方法、単位について

◆講義形式：オンデマンド

- 前半は講義資料をもとに学習し、後半は講義資料をもとに各自で演習に取り組みます。

◆Login address: Posted on Web Class

Webクラスは講義テーマごとに分け、教材や動画のログインアドレスも提供しますので、ご自分のペースで受講してください。

◆Earn credits:

- 各講義ごとにレポートがあります
- 取り組み、Webclassから提出するようにしてください

◆SAS, R, SPSS, STATA などの統計解析ソフトを使用してもかまいません。いずれかを各自で用意してください。

授業に関して何か質問があれば、いつでも連絡してください。コースについて何か質問がありましたら、いつでもメールまたはWebclassからお気軽にご連絡ください。

E-mail: aharada@belle.shiga-med.ac.jp

Webclass

6

This lecture will be given using SAS.

• R, SPSS user

- SPSS, Rを使用する場合は、別途補足資料を参照の上、課題を行ってください(SPSSは準備中)。

• Not full version of SAS user

- SAS製品版を利用できないが、SASを使ってみたいという方には、SAS Academic Editionの利用をお勧めします。
- SAS Academic Editionはインターネットに接続できる環境であれば利用できますので、ユーザー登録をしてご利用ください。
- また、ウェブクラスで入門用のサブリメントを作成しています。

- SAS Academic Editionは製品版と比較して機能が制限されていますが、本講義で使用する解析はこれでカバーできると思います。

JMPやSTATAなど他のソフトを使う場合は、相談してください。

7

本講座のオリエンテーションはこれで終了です。

講義や演習に関するご質問はいつでもどうぞ。



1 Introduction

Using the Statistical package

Goals of Today's Lectures:

統計パッケージの使用に慣れる

- 1) データをパッケージにアップロードできる
- 2) データの基本特性を様々なプロシジャーで把握できるようになる

Today's overview

1. 統計パッケージの使用法

- 1) 統計パッケージSASのイントロダクション
- 2) データの読み込み

2. 記述統計

- 1) 位置: 平均, メディアン, パーセント
- 2) ばらつき: range, inter-quartile range, CV
- 3) 分布: 歪度skewness, 尖度kurtosis, 正規性
- 4) 2変量の相関: Correlation

グラフ

Software packages for statistical analysis of data

- SAS
- R
- Python
- STATA

Programming statement (code) type

- SPSS
- JMP

Point-and-click interface

複数のパッケージが使用できることが望ましい !

NCD Reader Course students are encouraged to use SAS

Statistical Analysis System (SAS)

-Strength-

- 広く用いられている (in Business)
- 製薬企業にとっては申請データの解析・作成で用いられている (New Drug Application to the FDA)
- プログラムを共有財産として活用可能
- プログラムの妥当性が検証されている

R: program supply are by user-based (妥当性の面ではSASに軍配)

- データハンドリングに強い(あらゆる形式のデータに対しても柔軟に対応)
- 豊富な統計手法が用意されている行列言語が利用可能
- AIのプラットフォームもあり
- ユーザーのコミュニティ活動活発

-Weakness-

- プログラミングコードを使用するため、初期ユーザーへのパッケージの導入・教育に時間がかかる。
- ライセンスコストが高い
- 大学在学中は利用できるが、卒業後は利用できなくなることが多い。

R, Python等のメリット

メリット

- Free
 - どの環境でも使用できる
 - コード配布などの面でメリット
 - 書籍、論文等での配布例多い
- ユーザーが多い、書籍等豊富
- AI系の解析への拡張性が高い
- 新しい解析への対応が早い
- Rについては、RstudioやEZR(point-click型)など使用しやすい統合インターフェイス環境が整ってきている

デメリット

- 新しいプログラムのValidation
 - 近年は公開にあたりチェック機能が充実

自分のPCでパッケージを使用するには SAS

- SAS OnDemand Academics(無償)
 - https://www.sas.com/ja_jp/software/on-demand-for-academics.html
 - 登録が必要
 - クラウド環境



サインイン


- ①SAS プロファイルを登録
- ②SAS OnDemandの登録。
- ③SAS Studioの利用。

SAS studio画面

- ①コード: プログラムを各画面
- ②ログ、③結果、④データセット画面

On-demand版[コード]画面

SAS/パッケージ版(有料)の画面



1) A brief Introduction to SAS

統計ソフト(パッケージ)の使用法

SASを起動してみよう



Double-click the SAS icon, and SAS will launch.

Display Manager System(DMS)は、多くのウィンドウを持ち、連動してSASシステムを操作することができる。




Fig. SAS Startup Screen

Basic operation of SAS environment

主なウィンドウの使い方は次のとおり

1. プログラム・エディタ・ウィンドウ
SASプログラムの編集
2. ログウィンドウ
SASプログラムの実行経過に関するメッセージなどの情報を表示する
3. 出力ウィンドウ
SASプログラムの実行結果を表示する
4. Resultウィンドウ
SASプログラムの実行状況を確認することができる

5. エクスプローラウィンドウ
ライブラリ等で実行中のSASデータセットを確認することができます。

ウィンドウ自体の大きさや位置は、状況に応じて変更可能
各ウィンドウは、マウスで領域をクリックすることで起動し、各領域で作業できる

SAS Data set

- SASのデータセットは、変数×観測値 の長方形の形をしており、多変数データの基本的なパターンである

SAS Data Set Example 1

ID	年齢	性	治療群	改善度	除外・脱落コード
1	48	F	1	1	0
2	52	M	2	1	.
3	64	F	1	2	0
4	60	M	1	1	2

変数の種類は2つ。
数値型と文字型
". [ピリオド]"は欠損値を示す。

SAS Data Set Example 2

ID	測定日	薬量	最大血圧	最小血圧
1	90/02/04	10	165	109
1	90/02/05	20	155	97
1	90/02/06	20	154	90
2	90/01/09	20	138	101
2	90/01/10	20	129	89

SAS program structure

□ Data step

- Statement "Data.....; Run;"
- Data loading, direct input, processing, generation, etc.

```
Data example2;
set example;
bmi=weight/(height/100)**2;
Run;

Proc means data=example2;
var bmi;
by sex;
Run;
```

□ PROC step

- Statement "PROC.....; Run;"
- Call each procedures and perform statistical analysis.

2) Reading data

SASにおけるデータ読みこみ方法は様々ある

Reading Data ① Direct

• 直接入力する:

- INPUT文で、変数名を列挙
- 文字列データは、変数名の後\$をつける。

*SAS のデータセットと変数名は、最初の文字が数字であってはいけない

- CARDS(またはdataline)ステートメントの後に、生データを記載する

DATA Step Example

```
data test;
input id age sex $ arm effect drop;
cards;
1 48 F 1 1 0
2 52 M 2 1 0
3 64 F 1 2 0
4 60 M 1 1 2
run;
```

All SAS programming statements end with a semicolon (;).

DATA Step Example

```
data test;
input id age sex $ arm effect drop;
cards;
1 48 F 1 1 0
2 52 M 2 1 0
3 64 F 1 2 0
4 60 M 1 1 2
run;
```

Reading Data ② import external files

- 外部ファイルを読み込んでSASデータセットに加工するには、次のDATAステップをコーディングします。
- INFILE文の中で一重引用符で囲んだデータファイルをインポート。
- ファイルの場所には注意してください。

```
data lab;
infile 'C:\lab.csv' delimiter=';' firstobs=2;
input age weight height h_bp l_bp tp got gpt alp ggpt bun;
age10=int(age/10);
run;
```

• Cドライブにあるlab.csvを読み込む。
csv形式は「delimiter=','」を指定してください。
データ開始行を「firstobs」で指定する。

「lab.csv」

	age	weight	height	h_bp	l_bp	tp	got	gpt	alp	ggpt	bun
1	43	61	147.5	110	76	7.6	19	14	4.4	10	11
2	62	56	144.3	158	70	7.6	27	20	5.9	7	15
3	40	46.5	146	110	76	7.3	14	12	3.1	8	16
4	71	57.5	146.5	186	118	8.5	22	14	7.5	22	15
5	50	58	156.5	160	96	7.3	15	13	5.9	8	14
6	53	53.5	144.8	150	90	7.6	25	20	6.9	12	13
7	54	50	139.3	164	100	7.1	20	17	4.2	23	18
8	76	40	136.5	130	70	7.7	24	16	4.7	12	19
9	62	48	151.9	114	76	6.8	20	17	5.4	10	14
10	62	49	154.4	142	88	8	24	17	5.5	16	13
11	48	48.5	150.2	108	70	7.4	14	14	4.7	9	12

options in the INFILE statement

- Delimiter=(DLM=)

Specify this when reading data whose variables are separated by characters other than single-byte spaces.

```
.csv      comma    DLM = ','
.txt     tab       DLM = '09'x
         space     DLM = ' '
```

25

Reading Data ③ SAS data set files

SASデータセットには、次の2種類がある

- 1) 保存された(永続的な)SASデータセット
ライブラリに保存されたデータセット
SASを終了しても消えない
- 2) 一時的なSASデータセット
ワークライブラリのSASデータセット
SASを終了すると消滅

26

Reading Data ③ SAS data set files

- SAS LIBRARYの指定

- LIBNAME statement
- LIBNAME *library name* 'save folder location'
 - Libname mysas 'c:**********';

- Loading a stored SAS data set

- SET statement
 - SET library name. SAS dataset;

```
Data data2;
  set mysas.data1;
run;
```


左の例
mysasライブラリに格納されてい
るデータセット "data1" をロード
し、"data2" に設定する。

27

Reading Data ④ IMPORT wizard

- The following Excel data (file name lab.csv).


1. FILE→Import



2. Next, select "CSV" in the import wizard, and select the file location and sheet



28



データの読み込みは
できそうですか？

PROC Step(SUBMIT)

- PROCステップとは、PROC文で始まり、RUN文で終わる一連のプログラムのことです。
- プロシージャごとに異なるオプションやステートメントがたくさんあり、それぞれのプロシージャを覚える必要があります(参照する必要があります)。

```
PROC ProcedureName Option;
  Statements....;
RUN;
```

Here is the **GLOBAL STATEMENT syntax** common to all procedures.

DATA = SAS data set name (if not specified, use the previous one)

VAR statement Specifies the variable to use

BY statement Perform processing by group

WHERE statement Limit the observations of interest



演習 #1

データセットを4つの方法で作成してみる。

プログラムは "dataset.txt" に示されており、これを参照し、データの読み方として4つの方法を練習してください。

Reading data methods

- 1) Direct
- 2) Infile
- 3) SAS dataset
- 4) Import wizard

Today's overview

1. 統計パッケージの使用法

- 1) 統計パッケージSASのイントロダクション
- 2) データの読み込み

2. 記述統計

- 1) 位置: 平均, メディアン, パーセント
- 2) ばらつき: range, inter-quartile range, CV
- 3) 分布: 歪度skewness, 尖度kurtosis, 正規性
- 4) 2変量の相関: Correlation

グラフ

The distributions of numeric variables

SASを使って、以下のような指標を評価してみます。

位置: 平均値、中央値、パーセンタイル

分散: 範囲、四分位範囲、CV

分布: 歪度、角化度、正規性

2変数間の関連性 相関

例題

• Health survey data

- N=421
- Age 40-60yrs.
- Variable
 - SEX, AGE, Systolic Blood Pressure (SBP), Diastolic blood pressure (DBP)
 - Urinary Sodium (SALT)
- Dataset name=health

Dataset health (health_data.txt)

```
*****
01 health_data.txt
*****
/*data description "health data" */
data health; /*dataset name*/
input sex $ age sbp dbp salt; /*"$" indicates character variable*/
cards;
F 64 137 86 13.4
F 55 97 66 8.9
F 52 151 93 12.7
F 63 105 75 10.4
F 66 139 71 6.9
F 48 132 85 10.1
F 53 129 67 7.4
F 62 138 85 8.0
.
.
.
;
/* example of retain statement*/
data health2;
set health;
retain id 0;
id=id+1;
run;
```

データセット "health" にはユニークIDがない。
→データセット "health2" は、"health" に新たにID
変数を追加しています

Check the loaded dataset with "Proc print".



Q1. Create Dataset

Create a Dataset "health" to "health2".

"health"
The SAS System

Obs	sex	age	sbp	dbp	salt
1	F	64	137	86	13.4
2	F	55	97	66	8.9
3	F	52	151	93	12.7
4	F	63	105	75	10.4
5	F	66	139	71	6.9
6	F	48	132	85	10.1
7	F	53	129	67	7.4
8	F	62	138	85	8.0
9	F	64	126	75	10.2
10	F	47	101	73	9.3
11	F	67	133	65	9.2
12	F	50	97	60	7.9
13	F	58	104	69	10.6
14	F	61	109	65	9.4
15	F	55	117	69	10.1

SAS code

```
data health2;
set health;
retain id 0;
id=id+1;
run;
```

"health2"
The SAS System

Obs	sex	age	sbp	dbp	salt	id
1	F	64	137	86	13.4	1
2	F	55	97	66	8.9	2
3	F	52	151	93	12.7	3
4	F	63	105	75	10.4	4
5	F	66	139	71	6.9	5
6	F	48	132	85	10.1	6
7	F	53	129	67	7.4	7
8	F	62	138	85	8.0	8
9	F	64	126	75	10.2	9
10	F	47	101	73	9.3	10
11	F	67	133	65	9.2	11
12	F	50	97	60	7.9	12
13	F	58	104	69	10.6	13
14	F	61	109	65	9.4	14
15	F	55	117	69	10.1	15

Create a variable "id"
of identification

Use Univariate procedure 形状、位置、分布の指標を確認

1. Location
 - 1) Mean
 - 2) Median
 - 3) Mode
 - 4) Percentile
2. Variability dispersion
 - 1) Variance
 - 2) SD
 - 3) Range
 - 4) Inter-quartile range
3. Shape
 - 1) Skewness 歪度
 - 2) Kurtosis 尖度

PROC univariate ① code

•PROC UNIVARIATE

```
proc univariate option data=dataset name;
var variable list;
[by stratified variable;]
run;
```


PROC univariate ②

```
proc univariate data=health2
var age;
run;
```


- Variability dispersion
- 1) Variance
 - 2) SD
 - 3) Range
 - 4) Inter-quartile range
- Shape
- 1) Skewness
 - 2) Kurtosis
- Location
- 1) Mean
 - 2) Median
 - 3) Mode
 - 4) Percentile

The SAS System			
The UNIVARIATE Procedure			
Variable: age			
Statistics			
N	421	Sum Weights	421
Mean	58.9049883	Sum Observations	24739
Std Deviation	7.81570548	Variance	61.0861985
Skewness	-0.8750078	Kurtosis	-0.3284562
Uncorrected SS	1486441	Corrected SS	29026.1995
Coeff Variation	13.2684371	Std Error Mean	0.0009175
Basic Statistical Measures			
Location		Variability	
Mean	58.90499	Std Deviation	7.81571
Median	61.00000	Variance	61.08619
Mode	65.00000	Range	20.00000
		Interquartile Range	11.00000
Tests for Location: Mu=60			
Test	Statistic	p-Value	
Student's t	5	0.040399	Pr > t = 0.0003
Sign	58	270.5	Pr > S = 0.0003
Signed Rank	5	44415.5	Pr > S = 0.0003
Quantiles (Definition 1)			
Level	Quantile		
100% Max	85		
99%	83		
95%	80		
90%	77		
75% Q3	65		
50% Median	61		
25% Q1	58		
10%	55		
5%	52		
1%	49		
0% Min	45		

PROC univariate ③ Shape 歪度 Skewness(b_1), 尖度 Kurtosis(b_2)



PROC univariate ④ Boxplot 箱ひげ図




Q2 Use Univariate procedure
形状、位置、分布指標を確認する (var= SBP, DBP)

PROC univariate ⑤ histogram


proc univariate data=health plot normal;

```
var salt;  
class sex;  
histogram salt/ endpoints=3 to 19 by 1;  
id id;  
label salt='Salt intake';  
run;
```

Scales from 3 to 19, with intervals of 1




PROC univariate ⑥ Normal probability plot (Q-Qplot) 正規確率プロット



- データセットがほぼ正規分布しているかどうかを評価するためのグラフィカルな手法
- 正規確率プロットは次のように構成される。
 - 縦軸: 順序付けられた応答値
 - 横軸: 正規順序統計量の中央値

PROC univariate ⑥ Normal probability plot

- 正規確率プロットにより、データは正規分布しているか？判断します
- 正規性からの逸脱はどのようなものか（データが歪んでいる、予想よりテールが短い、予想よりテールが長い）？



Q3 ヒストグラム

- Q3-1
 - Create a histogram of salt intake for each sex.
- Q3-2
 - Create a histogram for each gram of salt.

Today's overview

1. Usage of Statistical Software (package)

- Brief Introduction to SAS
- Reading Data


2. Description of Data

- Location: mean, median, percentile
- Dispersion: range, inter-quartile range, CV
- Distribution: skewness, kurtosis, Normality
- Association between two variables: Correlation

相関

- 相関は、2つの変数間の関連の強さ、線形の関連性を測定する二変量解析

→ 相関係数は
のA,B,Cはすべて1.0である
→ 必ずしも一致の指標
とはならない。



- 相関係数の値は+1~-1の間で変化する。
- 相関係数の値が0に向かうほど、2つの変数の関係は弱くなる

Pearson product-moment correlation coefficient (usually denoted by "r")

$$\frac{\sum (x - \bar{x})(y - \bar{y})}{\sqrt{\sum (x - \bar{x})^2 \sum (y - \bar{y})^2}} = \text{Cov}(x, y) / \sqrt{V(x)V(y)}$$




FIGURE 8-11 Hypothetical examples illustrating the high sensitivity of Pearson's correlation coefficient to the range of values and to the presence of outliers (extreme values).

Spearman correlation coefficient or rank correlation coefficient (denoted by "ρ")

- 2つの変数間の関係の強さを測定するノンパラメトリックな検定。

$$\rho = 1 - \frac{6}{n^3 - n} \sum_{i=1}^n (R_i - R_i')^2$$

ρ = Spearman rank correlation

R_i, R_i' = rank

R_i - R_i' = the difference between the ranks of corresponding variables

n = number of observations

- (x,y) を順位データ(1~n)として変換し、ピアソン相関係数を計算する。
- 同値のデータがある場合は、平均順位として与えられる。

Kendall correlation coefficient (denoted "τ(タウ)")

- 2つの変数間の関係の強さを測定するノンパラメトリック検定
- aとbの2つの標本を考え、それぞれの標本サイズをnとすると、a bの組合せの総数はn(n-1)/2

$$\tau = \frac{n_c - n_d}{\frac{1}{2} n(n-1)} \quad \begin{array}{l} n_c = \text{Number of concordant} \\ n_d = \text{Number of discordant} \end{array}$$

Ex. (x,y) = (1,1) (2,3) (3,5) (5,4)

(1,1)		(2,3)	(3,5)	(5,4)
(2,3)	↔		(3,5)	(5,4)
(3,5)				(5,4)

□ . . . concordant (normal order)
■ . . . discordant (reverse order)

$$\tau = \frac{5 - 1}{\frac{1}{2} \times 4 \times (4 - 1)} = \frac{4}{6} = \frac{2}{3}$$



#Q4 Use CORR 線形結合の強さを確認

```
proc corr option data=dataset name;
```



pearson, spearman, kendall

```
[var var.list;]
```

```
[with var.list;]
```

```
run;
```

Option
nomiss: Use only observations with no deficiencies
If not specified, all the observations that exist for each combination are used for the calculation.

Q4: health2データセットを用いて、血圧と食塩摂取量の相関係数を算出せよ。

```
/*corr procedure*/
```

```
proc corr pearson spearman kendall data=health2;
```

```
var sbp dbp salt;
```

```
run;
```

Correlation coefficients

Pearson

Pearson Correlation Coefficients, N = 421 Prob > r under H0: Rho=0			
	sbp	dbp	salt
sbp	1.00000	0.71894 <.0001	0.17764 0.0002
dbp	0.71894 <.0001	1.00000	0.15371 0.0016
salt	0.17764 0.0002	0.15371 0.0016	1.00000

Spearman

Spearman Correlation Coefficients, N = 421 Prob > r under H0: Rho=0			
	sbp	dbp	salt
sbp	1.00000	0.71932 <.0001	0.15706 0.0012
dbp	0.71932 <.0001	1.00000	0.14794 0.0023
salt	0.15706 0.0012	0.14794 0.0023	1.00000

Kendall

Kendall Tau b Correlation Coefficients, N = 421 Prob > tau under H0: Tau=0			
	sbp	dbp	salt
sbp	1.00000	0.53927 <.0001	0.10777 0.0012
dbp	0.53927 <.0001	1.00000	0.10160 0.0023
salt	0.10777 0.0012	0.10160 0.0023	1.00000

```
/*corr procedure*/;
```

```
proc corr pearson spearman
```

```
kendall data=health2;
```

```
var sbp dbp salt;
```

```
run;
```

Output format for Matrix type ①

Simple Statistics						
Variable	N	Mean	Std Dev	Median	Minimum	Maximum
age	244	58.45492	8.05805	61.00000	40.00000	69.00000
sbp	244	122.72861	16.27189	123.00000	91.00000	187.00000
dbp	244	72.23361	9.50280	71.00000	49.00000	100.00000
salt	244	9.32541	2.10178	9.20000	4.90000	17.20000

Pearson Correlation Coefficients, N = 244 Prob > r under H0: Rho=0			
	sbp	dbp	salt
age	0.18953 0.0126	0.06836 0.2875	0.12452 0.0521

Spearman Correlation Coefficients, N = 244 Prob > r under H0: Rho=0			
	sbp	dbp	salt
age	0.14196 0.0266	0.07555 0.2397	0.12452 0.0488

Kendall Tau b Correlation Coefficients, N = 244 Prob > tau under H0: Tau=0			
	sbp	dbp	salt
age	0.09704 0.0272	0.05322 0.2338	0.08532 0.0536


```
proc corr pearson spearman kendall  
plots=matrix(histogram) data=health;
```

```
with age;
```

```
var sbp dbp salt;
```

```
by sex;
```

```
run;
```



Output format for Matrix type ②

```
*corr procedure;
```

```
ods pdf file='F:\corr.pdf';
```

```
proc corr pearson
```

```
spearman kendall
```

```
plots=matrix
```


```
data=health;
```

```
var sbp dbp salt;
```

```
run;
```


```
ods pdf close;
```

```
run;
```



Output format for Matrix type ③

```
*corr procedure;
ods pdf
file='F:\%corr.pdf';
proc corr pearson
spearman kendall
plots=matrix(histogram)
data=health;
var sbp dbp salt;
run;
ods pdf close;
run;
```



Polychoric / Polyserial Correlations

- Polychoric correlations (=tetrachoric correlation)
 - 2つの観測されたカテゴリ変数の間の相関。
- Polyserial Correlations
 - 連続変数とカテゴリカル変数の相関
- 血圧と食塩摂取量の相関
 - SBPと食塩摂取量
 - 高血圧カテゴリーと食塩摂取量
 - ピアソン
 - スピアマン
 - ポリシリアル(高血圧と食塩摂取量)

Polyserial correlation

```
proc corr data=health2 pearson polyserial;
with HTN_c;
var age salt sbp;
run;
```

"HTN_c" is JSH hypertension grade as categorical variable

```
proc corr data=health2 pearson;
var age salt sbp;
run;
```

Output Delivery System (ODS)
Excel output

```
ODS EXCEL FILE = 'file-specification' OPTIONS ( suboption(s) );
... Procedures ...
ODS EXCEL CLOSE;
```

ここで様々なオプションを指定することで、Excelの出力をカスタマイズすることができます。

<code>start_at='2,3'</code>	Setting the output position (column, row)
<code>sheet_name='MY_SHEET'</code>	Set (input) the sheet name.
<code>sheet_interval='XXXXXX'</code>	Set up how the sheets are divided.

Bygroup	BYグループごとにシートを分ける。
TABLE	プロシージャが出力する各テーブルごとにシートを分ける。
PROC	プロシージャで出力するテーブルごとにシートを区切る。
NONE	シートを区切らない(1枚のシートにすべてを出力する)

ODS Excel output

```
ods excel file='F:\%corr.xlsx' OPTIONS( sheet_interval='proc' );
proc corr pearson spearman kendall Plots=matrix data=health;
  var sbp dbp salt;
run;

proc corr data=health2 pearson spearman kendall
plots=matrix(histogram) data=health;
  var sbp dbp salt;
run;

ods excel close;
run;
```

ODS pdf出力

```
ods pdf file='F:\%corr.pdf';
ods proclabel='matrix_corr_1';
proc corr pearson spearman kendall
plots=matrix data=health;
  var sbp dbp salt;
run;


ods proclabel='matrix_corr_2';
proc corr data=health2 pearson spearman kendall
plots=matrix(histogram) data=health;
  var sbp dbp salt;
run;
ods pdf close;
run;
```

Excel

手順で出力した表ごとにシートを分ける。

PDF

Create a bookmark with a specified label



Summary

1. Usage of Statistical Software (package)

- 1) Brief Introduction to SAS
- 2) Reading Data

2. Description of Data

- PROC Univariate**
- 1) Location: mean, median, percentile
 - 2) Dispersion: range, inter-quartile range, CV
 - 3) Distribution: skewness, kurtosis, Normality
- PROC CORR**
- 4) Association between two variables: Correlation

Exercise

•講義スライドに示された以下のQ1～Q4の課題について、統計パッケージを使って結果が再現できることを確認せよ。

- Q1 データセット("health"→"health2")を作成する。
- Q2 一変量手順を用いて、形状、位置、分布の指標を確認する(var= SBP, DBP)。
- Q3 ヒストグラム
- Q4 "health2 "データセットを用いて、血圧と食塩摂取量の相関係数を計算する。

65

R 他

以下は余裕があれば

66

自分のPCでパッケージを使用するには JMP(JMP Pro) 製品版


- SAS社の製品
- 現在最新版は ver.16
- データの視覚化、クレンジング等の作業が行いやすい
- かなりの高度な解析までカバー
- テキスト解析
- 構造方程式 (SEM) などカバー



67


自分のPCでパッケージを使用するには SPSS

- 滋賀医科大学内ではMMCにてライセンス提供(使用可能)




68

自分のPCでパッケージを使用するには R studio



R studio




R-studio Cloud版

RStudio Cloud Introduction memo


1 Register as a user (ユーザ登録を行う)

RStudio Cloud <https://www.rstudio.com/products/cloud/> (<https://www.rstudio.com/products/cloud/>)



Rソフトを自身のPCにインストールして使用してもよいが、クラウド版は、
・導入までの手間が回避
・いつでもどこでも最新環境が使用できるなどのメリットもある


Rstudio cloud screen



データセットのアップロード

3 Upload dataset


To upload datasets, click on the Upload button in environment window. Click the "File selection button", select the file to upload, and click "OK".



73

NCD Epidemiology Research Center (NERC)

データセットの読み込み




74

NCD Epidemiology Research Center (NERC)

必要なパッケージの読み込み、コードの入力などを行いながら解析

4 Enter code on the Source screen to start analysis.

Summary statistics using "Lab" dataset




75


NCD Epidemiology Research Center (NERC)

講義の例題をRで確認してみる



・「helath2.csv」




Health2.csvをアップロード



Import datasetから CSV形式は「Text(base)」



コードを入力するため、New fileから「R Script」 を選択



#psych package

```
vars n mean sd median trimmed mad min max
X1 1 421 123.89 16.12 123 123.44 17.79 91 187
range skew kurtosis se
X1 96 0.36 0.29 0.79
```

#tableone

- Create summary tables like background information

Vars:
Variable names (columns) to be included in the table

```
library(tableone)
```

Strata:
Stratified Variables

```
tbl_1 <- CreateTableOne(vars = c("sex", "age", "sbp",
"dbp", "salt", "HTN_c"), strata = "age_category", factorVars
= c("sex", "HTN_c"), data = health2x)
```

factorVars:
Categorical variable out of vars

data: Data set name

```
tbl_1
```

```
tbl_1 %>%
```

```
print() %>%
```

```
write.csv(file = "tableone.csv")
```

Stratified by age_category					
	40s	50s	60s	p	test
n	64	113	244		
sex = M (%)	23 (35.9)	43 (38.1)	111 (45.5)	0.234	
age (mean (SD))	44.42 (2.90)	55.12 (2.94)	64.45 (2.57)	<0.001	
sbp (mean (SD))	117.70 (15.04)	123.86 (16.15)	125.52 (16.04)	0.002	
dbp (mean (SD))	73.05 (11.85)	74.75 (10.47)	74.03 (9.69)	0.566	
salt (mean (SD))	9.02 (1.66)	9.35 (1.92)	9.46 (2.16)	0.312	
HTN_c (%)				0.087	
1	36 (56.2)	45 (39.8)	80 (32.8)		
2	9 (14.1)	18 (15.9)	47 (19.3)		
3	15 (23.4)	37 (32.7)	99 (40.6)		
4	4 (6.2)	12 (10.6)	15 (6.1)		
5	0 (0.0)	1 (0.9)	2 (0.8)		
6	0 (0.0)	0 (0.0)	1 (0.4)		

tableone.csv

	40s	50s	60s	p	test
n	64	113	244		
sex = M (%)	23 (35.9)	43 (38.1)	111 (45.5)	0.234	
age (mean (SD))	44.42 (2.90)	55.12 (2.94)	64.45 (2.57)	<0.001	
sbp (mean (SD))	117.70 (15.04)	123.86 (16.15)	125.52 (16.04)	0.002	
dbp (mean (SD))	73.05 (11.85)	74.75 (10.47)	74.03 (9.69)	0.566	
salt (mean (SD))	9.02 (1.66)	9.35 (1.92)	9.46 (2.16)	0.312	
HTN_c (%)				0.087	
1	36 (56.2)	45 (39.8)	80 (32.8)		
2	9 (14.1)	18 (15.9)	47 (19.3)		
3	15 (23.4)	37 (32.7)	99 (40.6)		
4	4 (6.2)	12 (10.6)	15 (6.1)		
5	0 (0.0)	1 (0.9)	2 (0.8)		
6	0 (0.0)	0 (0.0)	1 (0.4)		

QQプロット

```
qqnorm(x)
```

直線を赤(col=2)で描く

```
qqline(x, col=2)
```

One-sample Kolmogorov-Smirnov test

```
data: scale(x)
```


D = 0.037474, p-value = 0.5955

alternative hypothesis: two-sided

Shapiro-Wilk normality test

```
data: x
```


W = 0.98514, p-value = 0.0002601




ks.test(x, "pnorm",
mean=mean(x), sd=sd(x))

shapiro.test(x)

Save Figure




The screenshot shows the RStudio interface. On the left, the console displays R code for creating a scatter plot. On the right, a scatter plot of 'sbp' (systolic blood pressure) versus 'salt' is shown. A red arrow points from the 'Export' menu in the top right corner of the plot area to the 'Save as Image...' option.



Box plot

```
#boxplot 1
boxplot(x)
#horizontal=TUREで横向きになる
boxplot(x, horizontal=TRUE)
```

```
#boxplot 2
health2 %>%
  ggplot(aes(sex,sbp)) +
  geom_boxplot() +
  labs(title = "Distribution of cty relative to drv",
        x = "sex",
        y = "sbp") +
  theme_minimal() +
  scale_y_continuous(breaks = seq(70,200,10))
```



```
> health2$HTN_c<-
as.character(health2$HTN_c)
> health2 %>%
+ ggplot(aes(sex)) +
+ geom_bar(aes(fill = HTN_c))
>
```

