

3 : Biostatistics 一般線形モデル(1)

線形回帰

Course Content

This course will be divided in 11 chapters as follow

Fundamental series


- 1 Introduction
- 2 Group Comparison
- 3 General linear model (1) linear regression
- 4 Generalized linear model Logistic, Poisson
- 5 Survival analysis
- 6 Principal component analysis, Factor analysis, Cluster analysis, Latent class analysis

Advanced series Ref. Circulation CVD stat guideline

- 7 General linear model (2) ANOVA MIXED
- 8 Reporting Guide: PRISMA Meta-analysis
- 9 Reporting Guide: CONSORT/STROBE
- 10 Missing, Correlated data
- 11 Introduction to causal inference: DAG, propensity score

一般線形モデル 一般化線形モデル

•Development of linear models



一般線形モデル?

•一般線形モデル

$$y = \alpha + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_i x_i + \varepsilon$$

$$y = X\beta + e$$

It can be expressed by this equation

•重回帰分析($i \leq 2$)

$$\begin{bmatrix} y_1 \\ \vdots \\ y_n \end{bmatrix} = \begin{bmatrix} 1 & x_{n1} & x_{n2} \\ \vdots & \vdots & \vdots \\ 1 & x_{n1} & x_{n2} \end{bmatrix} \begin{bmatrix} \alpha \\ \beta_1 \\ \beta_2 \end{bmatrix} + \begin{bmatrix} e_1 \\ \vdots \\ e_n \end{bmatrix} \quad y = X\beta + e$$

•ANOVA, ANCOVA

$$\begin{bmatrix} y_{11} \\ y_{12} \\ y_{21} \\ y_{22} \\ y_{31} \\ y_{32} \end{bmatrix} = \begin{bmatrix} 1 & 1 & 0 & 0 \\ 1 & 1 & 0 & 0 \\ 1 & 0 & 1 & 0 \\ 1 & 0 & 1 & 0 \\ 1 & 0 & 0 & 1 \\ 1 & 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} \mu \\ T_1 \\ T_2 \\ T_3 \end{bmatrix} + \begin{bmatrix} e_{11} \\ e_{12} \\ e_{21} \\ e_{22} \\ e_{31} \\ e_{32} \end{bmatrix} \quad y = X\beta + e$$

一般線形モデル?

• (一般)線形モデルで十分か?

- 応答変数(y)は正規分布に従うか?
- 誤差は分散の均質性と正規分布と仮定できるか?



- この仮定を満たさない場合はどうするか?
- カテゴリカルデータやカウントデータをどうするか?

一般線形モデル→一般化線形モデル

GLMは正規分布だけでなく、指数族(二項、ガンマ、ポアソンなど)の分布も扱うことができます!




Fig.1 : 一般線形モデル




Fig.2 : 一般化線形モデル(例: ポアソン)

GLMは以下の3つの要素で構成される

1. 確率分布の指数族

指数族(二項、ガンマ、ポアソンなど)

2. 線形予測量 $\eta = X\beta$

線形予測量(η)は独立変数の情報モデルに取り込む量である。 η は未知パラメータ β の線形結合(したがって「線形」)で表され、線形結合の係数は独立変数の行列 X として表される。

3. リンク関数

ある式を線形に変換する関数。


Link function

• 式を線形に変換する関数

Distribution	Support	Probability Distribution	family	Frequently used link functions	Variance	Mean function
Normal	real: $(-\infty, +\infty)$					$\mu(\beta)$
Exponential	real: $(0, +\infty)$					$\mu(\beta)$
Gamma	real: $(0, +\infty)$					$\mu(\beta)$
Inverse Gaussian	real: $(0, +\infty)$					$\mu(\beta)$
Poisson	integer: $0, 1, 2, \dots$	Discrete variable	Bernoulli	binomial	logit	$\mu(1 - \mu)$
Bernoulli	integer: $\{0, 1\}$		Binomial	binomial	logit	$\mu(1 - \mu) (1 - \mu)$
Binomial	integer: $0, 1, \dots, K$		Poisson	poisson	log	μ
Categorical	K-vector of integer element in the v	Continuous variable	Gamma	gamma	log かな?	μ^2
Multinomial	K-vector of integer: $[0, N]$		Normal	gaussian	identity	$-\frac{1}{\mu^2}$

一般線形モデル 一般化線形モデル

•Development of linear models



線形回帰

- x に対する y の線形回帰
- y : 応答, 従属変数
- x : 説明変数, 独立変数

- 予測 $\hat{y} = a + bx$
- 残差 $y - \hat{y}$





Fig.1 : (General) liner model

回帰と最小二乗法





$$y = X\beta + \varepsilon$$

観測値
ベクトル
 $n \times 1$

デザイン
行列
 $n \times p$

パラメータ
ベクトル
 $p \times 1$


残差
ベクトル
 $n \times 1$



$$= \text{交互作用項を含む線形回帰} \quad y = b_0 + b_1x_1 + b_2x_2 + b_3x_1x_2$$

食の交互作用の例

$$b_0 = 100, b_1 = 100, b_2 = 3, b_3 = -0.1$$



正の交互作用の例

$$b_0 = 100, b_1 = 0, b_2 = 0, b_3 = -0.1$$





図3.29 交互作用の意味

多重共線性

■ 通常の回帰分析
(x_1 と x_2 の相関が低い)



■ 多重共線性がある状態
(x_1 と x_2 の相関が高い)




図3.46 多重共線性

13

解析の手順 線形モデルのあてはめとモデル診断

なぜ線形モデルを使うのか？

- データ削減
- 内挿か外挿か？
- パラメータ値の解釈

仮定は正しいか？

- $y = x + \text{誤差}$
- 誤差の変動: 平均は0, 分散は等しい, 独立, ほぼ正規分布


回帰診断

- 残差の検討と影響度分析

14

線形モデルフィッティング Anscombe's quartet

- 単純な記述統計量はほぼ同じだが、分布が大きく異なり、グラフにすると大きく異なって見える4つのデータセット。
- これらは、統計学者Francis Anscombeによって、データを分析する前にグラフ化することの重要性と、外れ値やその他の影響力のある観測値が統計的性質に及ぼす影響の両方を示すために、1973年に作成されたものです。




	I		II		III		IV	
	X _i	Y _i	X _i	Y _i	X _i	Y _i	X _i	Y _i
	10	8.04	10	9.14	10	7.46	8	6.58
	8	6.95	8	8.14	8	6.77	8	5.76
	13	7.58	13	8.74	13	12.74	8	7.71
	9	8.81	9	8.77	9	7.11	8	8.84
	11	8.33	11	9.26	11	7.81	8	8.47
	14	9.96	14	8.10	14	8.84	8	7.04
	6	7.24	6	6.13	6	6.08	8	5.25
	4	4.26	4	3.10	4	5.39	19	12.5
	12	10.84	12	9.13	12	8.15	8	5.56
	7	4.82	7	7.26	7	6.42	8	7.91
	5	5.69	5	4.74	5	5.73	8	6.89
AVG	9	7.50	9	7.50	9	7.50	9	7.50
VAR	11	4.127	11	4.128	11	4.123	11	4.123
CORREL	0.816		0.816		0.816		0.817	

15

線形モデルフィッティング Anscombe's quartet

- 形状は全く異なるが、要約統計では類似している4つのデータセット



モデル診断をやってみよう

16



Program and output (SAS) PROC REG

Q1: Anscombeのデータで回帰分析をしてみよう。
また、ans3のデータに対して robustreg を試してみよう。

```
data ans1;
input x y;
cards;
10 8.04
8 6.95
13 7.58
9 8.81
11 8.33
14 9.96
6 7.24
4 4.26
12 10.84
7 4.82
5 5.68
;
```

```
data ans2;
input x y;
cards;
10 9.14
8 8.14
13 8.74
9 8.77
11 9.26
14 8.10
6 6.13
4 3.10
12 9.13
7 7.26
5 4.74
;
```

```
data ans3;
input x y;
cards;
10 7.46
8 6.77
13 12.74
9 7.11
11 7.81
14 8.84
6 6.08
4 5.39
12 8.15
7 6.42
5 5.73
;
```

```
data ans4;
input x y;
cards;
8 6.58
8 5.76
8 7.71
8 8.84
8 8.47
8 7.04
8 5.25
19 12.5
8 5.56
8 7.91
8 6.89
;
```

```
proc reg data=ans1;
model y=x;
run;
```

```
proc reg data=ans1;
model y=x/r influence;
run;
```

```
proc robustreg
data=ans3 method=m;
model y=x;
run;
```

Program and output (SAS) PROC REG

```
proc reg data=dataset;
var var1 var2 .....;
model y= var1 var2 .....;
[response = explanatory var. list]
run;
```

Program and output (SAS) PROC REG data=ans1

Anscombe's data


The REG Procedure
Model: MODEL1
Dependent Variable: y

Number of Observations Read	11
Number of Observations Used	11


Analysis of Variance					
Source	DF	Sum of Squares	Mean Square	F Value	Pr > F
Model	1	27.51000	27.51000	17.99	0.0002
Error	9	13.76289	1.52919		
Corrected Total	10	41.27289			

Root MSE	1.23660	R-Square	0.6965
Dependent Mean	7.50091	Adj R-Square	0.6295
Coeff Var	16.48025		


Parameter Estimates					
Variable	DF	Parameter Estimate	Standard Error	t Value	Pr > t
Intercept	1	3.00009	1.12475	2.67	0.0257
x	1	0.50009	0.11791	4.24	0.0002



Program and output (SAS) PROC REG data=ans1



Program and output (SAS) PROC REG data=ans1



- RSTUDENT
 - 残差をその標準偏差推定値で割ったもの。
 - 値が±3を超えている場合は異常値である。
- LEVERAGE
 - 説明変数空間における外れ値
- Cook's D
 - 問題のオブザベーションを除外したときのリグレッサーの変化
 - $4/n$ を超える場合は注意

Program and output (SAS) PROC REG data=ans3


The REG Procedure
Model: MODEL1
Dependent Variable: y

Number of Observations Read	11
Number of Observations Used	11

Source	DF	Sum of Squares	Mean Square	F Value	Pr > F
Model	1	27.47001	27.47001	17.97	0.0022
Error	9	13.75619	1.52647		
Corrected Total	10	41.22620			


Root MSE	1.23631	R-Square	0.6663
Dependent Mean	7.50000	Adj R-Sq	0.6292
Coeff Var	16.48415		

Variable	DF	Parameter Estimate	Standard Error	t Value	Pr > t
Intercept	1	3.00245	1.12448	2.67	0.0256
X	1	0.49973	0.11788	4.24	0.0022



Linear Model Fitting Anscombe's quartet

- Four datasets, quite different in shape, but similar in summary statistics




	I	II	III	IV
	X ₁	X ₂	X ₃	X ₄
10	8.04	10	9.14	10
8	6.95	8	8.14	8
13	7.58	13	8.74	13
9	8.81	9	8.77	9
11	8.33	11	9.26	11
14	9.96	14	8.10	14
6	7.24	6	6.13	6
4	4.26	4	3.10	4
12	10.84	12	9.13	12
7	4.32	7	7.26	7
5	5.68	5	4.74	5
AVG	9	9	9	9
VAR	11	11	11	11
CORREL	0.816	0.816	0.816	0.817


Let's try Model Diagnosis

残差分析

システムティックパターンの有無を確認する。




Program and output (SAS) PROC REG data=ans1




25

Program and output (SAS) PROC REG data=ans2




26

Program and output (SAS) PROC REG data=ans3





27

Program and output (SAS) PROC REG data=ans4



28



変数選択

- 相関の高い変数をモデルに含めると係数が不安定になる(多重共線性)。
- 対策
- 変数の選択、合成変数の作成、事前情報の利用(ベイズ型)
- PROC reg では、ALL(全変数を一度に入力)、FORWARD(前方、増加)BACKWARD(後方、減少)、STEPWISE(増加/減少)を使用する。
- SLSとSLEはそれぞれモデル残差とモデル採用のp値基準



Q2 変数選択

- Q2のデータは、 $y=x_1+x_2+x_3$ +誤差(x_1, x_2, x_3 は独立)というモデルで作られています。
- x_4 は x_1 と高い相関がある
- x_5 は x_2 と高い相関がある
- x_6 - x_{15} は互いに独立であり、 y とも独立である。
- 変数選択を適用して、どのような結果が得られるか観察してください。

Program and output (SAS) variable selection for Q2

```
proc reg;
  model y=x1-x15;
run;
/* FORWARD*/
proc reg;
  model y=x1-x15/selection=forward sle=0.15;
run;
/* BACKWARD*/
proc reg;
  model y=x1-x15/selection=backward sls=0.15;
run;
/* STEPWISE*/
proc reg;
  model y=x1-x15/selection=stepwise sle=0.15 sls=0.15;
run;
/* ALL*/
proc reg;
  model y=x1-x15/selection=rsquare best=5 start=1 stop=5;
run;
```

FORWARD

変数追加法: ステップ 4
変数 x8 の追加: R2 乗 = 0.7229 C(p) = -2.1918

変数	自由度	平方和	平均平方	F 値	Pr > F
Model	4	272.81746	68.20436	82.27	<.0001
Error	85	102.97446	1.09447		
Corrected Total	89	375.79191			

変数	パラメータ 推定値	標準誤差	T 値	Pr > T
Intercept	0.01295	0.10738	0.01192	0.91043
x1	1.02018	0.11276	9.04475	<.0001
x2	0.87981	0.10629	8.22009	<.0001
x3	0.82774	0.10283	7.99157	<.0001
x8	-0.18008	0.11801	-1.52403	0.1304

条件数における値: 1.0485, 16.709

BACKWARD

変数削除法: ステップ 11
変数 x5 の削除: R2 乗 = 0.7229 C(p) = -2.1918

変数	自由度	平方和	平均平方	F 値	Pr > F
Model	4	272.81746	68.20436	82.27	<.0001
Error	85	102.97446	1.09447		
Corrected Total	89	375.79191			

変数	パラメータ 推定値	標準誤差	T 値	Pr > T
Intercept	0.01295	0.10738	0.01192	0.91043
x1	1.02018	0.11276	9.04475	<.0001
x2	0.87981	0.10629	8.22009	<.0001
x3	0.82774	0.10283	7.99157	<.0001
x8	-0.18008	0.11801	-1.52403	0.1304

条件数における値: 1.0485, 16.709

STEPWISE

ステップワイズ法: ステップ 4
変数 x8 の追加: R2 乗 = 0.7229 C(p) = -2.1918

変数	自由度	平方和	平均平方	F 値	Pr > F
Model	4	272.81746	68.20436	82.27	<.0001
Error	85	102.97446	1.09447		
Corrected Total	89	375.79191			

変数	パラメータ 推定値	標準誤差	T 値	Pr > T
Intercept	0.01295	0.10738	0.01192	0.91043
x1	1.02018	0.11276	9.04475	<.0001
x2	0.87981	0.10629	8.22009	<.0001
x3	0.82774	0.10283	7.99157	<.0001
x8	-0.18008	0.11801	-1.52403	0.1304

条件数における値: 1.0485, 16.709

R2 乗選択法

変数	R2 乗	モデルの自由度
1	0.3389	x2
1	0.3343	x5
1	0.2345	x1
1	0.2332	x4
1	0.1478	x3
2	0.5141	x1 x2
2	0.5106	x2 x4
2	0.5079	x1 x5
2	0.5044	x4 x5
2	0.4822	x2 x5
3	0.7171	x1 x2 x3
3	0.7162	x2 x3 x4
3	0.7122	x1 x3 x5
3	0.7111	x3 x4 x5
3	0.6366	x1 x2 x5
4	0.7238	x1 x2 x3 x4
4	0.7234	x1 x2 x3 x5
4	0.7231	x2 x3 x4 x5
4	0.7230	x2 x3 x4 x5
4	0.7198	x1 x3 x4 x5
5	0.7283	x1 x2 x3 x4 x5
5	0.7280	x2 x3 x4 x5 x5
5	0.7283	x1 x2 x3 x4 x5
5	0.7281	x1 x2 x3 x4 x5
5	0.7280	x1 x2 x3 x4 x5

X1,X2,X3,X8

X1-X4,X2-X5

PROC GLMSELECT

REG手順:

様々な変数選択が可能であるが、交互作用項を含む変数選択はできない。

GLMプロシージャ

交互作用項を含む回帰分析が可能ですが、変数選択は一切行えません。

GLMSELECT手順。

様々な変数選択方法が可能。
交互作用項を含む変数選択が可能。

```
proc reg data=data; model
  y=x1 x2 x3/selection=stepwise
  SLE=0.15 SLS=0.15;
run;

proc glmselect data=data;
  class c1 c2 c3;
  model y = x1 x2 x3 c1 c2 c3
  x1*x2 x1*c1
  /selection=stepwise(select=SL
  SLE=0.15 SLS=0.15);
run;
```

回帰モデルの拡張

- 0-1データに対するロジスティック回帰(sas/logistic)
- 頻度データに対するポアソン回帰 (sas/genmod)
- 生存時間データに対するCox回帰(sas/phreg)
- 一般化推定方程式(Generalized Estimating Equation)
- 反復測定データに対するGEE(sas/mixed, genmod, gee)
- 個人差を扱うことができるモデル
 - 線形: (sas/mixed)
 - 一般化線形: (sas/glmmix)
 - 非線形: (sas/nlmixed)

Report

- 講義のスライドにある以下の問1～問2の課題について、SASで結果が再現できることを確認し、出力結果を提出すること。
- Q1 Anscombe のデータに対する回帰分析
- Q2 変数の選択

Please submit via web class